



پایان نامه مقطع کارشناسی مهندسی برق - کنترل

تشخیص بیماری اختلال شناختی خفیف با استفاده از سیگنال‌های EEG و رویکردهای یادگیری عمیق

دانشجو:

سید محمدمتین بنی‌ساعدی

استاد راهنما:

دکتر امیرحسین نیکوفرد

استاد مشاور:

دکتر علی خادم

تابستان ۱۴۰۱

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ

تقدیم به:

پدر و مادر عزیزم، که همواره وجود مهرانگیزتان در مراحل زندگی، انگیزه ادامه راه بوده است.

بوسه بر دستان پرمهرتان.

تاییدیه هیئت داوران

هیئت داوران پس از مطالعه پایان نامه و شرکت در جلسه دفاع از پایان نامه تهیه شده تحت عنوان:
تشخیص بیماری اختلال شناختی خفیف با استفاده از سیگنال های EEG و رویکردهای یادگیری عمیق
 توسط آقای سیدمحمدمتین بنی ساعدی صحت و کفایت تحقیق انجام شده را برای اخذ درجه کارشناسی
 در رشته: مهندسی برق گرایش: کنترل مورد تأیید قرار می دهند.

امضاء

آقای دکتر امیرحسین نیکوفرد

۱. استاد راهنما

امضاء

آقای دکتر علی خادم

۲. استاد مشاور

امضاء

آقای دکتر مهدی دلربایی

۳. استاد ارزیاب

اظهارنامه دانشجو

اینجانب سیدمحمدمتین بنی ساعدی دانشجوی مقطع کارشناسی رشته مهندسی برق گواهی می نمایم که مطالب ارائه شده در این پایان نامه با عنوان:

تشخیص بیماری اختلال شناختی خفیف با استفاده از سیگنال های EEG و رویکردهای یادگیری عمیق
با راهنمایی استاد محترم دکتر امیرحسین نیکوفرد و با مشورت استاد محترم دکتر علی خادم توسط شخص
اینجانب انجام شده است. صحت و اصالت مطالب نوشته شده در این پایان نامه تایید می شود و در تدوین متن پروژه
قالب مصوب دانشگاه را به طور کامل رعایت کرده ام.

امضاء



حق چاپ و تکثیر و مالکیت بر نتایج

۱- حق چاپ و تکثیر این پایان نامه متعلق به نویسنده و استاد راهنمای آن است. هرگونه تصویربرداری از کل یا بخشی از پروژه تنها با موافقت نویسنده یا استاد راهنما یا کتابخانه دانشکده‌های مهندسی برق و کامپیوتر دانشگاه صنعتی خواجه نصیرالدین طوسی مجاز است.

۲- کلیه حقوق معنوی این اثر متعلق به دانشگاه صنعتی خواجه نصیرالدین طوسی است و بدون اجازه کتبی دانشگاه قابل واگذاری به شخص ثالث نیست.

۳- استفاده از اطلاعات و نتایج موجود در پروژه بدون ذکر مرجع مجاز نیست.

تشکر و قدردانی

از استاد عزیز و محترم آقای دکتر امیرحسین نیکوفرد که استاد راهنمای این پروژه بودند بابت راهنمایی‌ها و مهربانی‌هایشان سپاس گزارم.

تشکر ویژه از استاد عزیز و محترم آقای دکتر علی خادم دارم که همواره در طول انجام این پایان‌نامه، با مشورت‌ها و راهنمایی‌های بی‌دریغ‌شان، مسیر راه را هموار کردند.

از تمامی استادان عزیز و ارجمندی که در دوره کارشناسی از آنها درس علم و زندگی آموختم، قدردانی می‌کنم و آرزوی سربلندی ایشان را دارم.

در نهایت از استاد محترم آقای دکتر مهدی دلربایی که زحمت ارزیابی این پایان‌نامه را می‌کشند، تشکر می‌کنم.

چکیده

اختلال شناختی خفیف^۱ (MCI) نوعی اختلال عصبی است که معمولاً در افراد مسن رخ می‌دهد و شامل اختلالات شناختی همراه با اختلالات جزئی در فعالیتهای روزمره زندگی می‌شود.

اکثر افرادی که به بیماری زوال عقل (آلزایمر) مبتلا می‌شوند، در ابتدا دچار MCI بوده‌اند. نکته قابل توجه این است که درمان در مرحله MCI می‌تواند مانع از پیشرفت بیماری و ابتلا به آلزایمر شود، بنابراین تشخیص به موقع MCI اهمیت فراوانی پیدا می‌کند.

در این پایان‌نامه هدف تشخیص افراد مبتلا به MCI بر اساس الکتروانسفالوگرافی^۲ (EEG) و با کمک روش‌های یادگیری عمیق^۳ بوده است. یادگیری عمیق مجموعه روش‌هایی برای بازشناسی الگو است که در سال‌های اخیر قدرت زیادی را از خود نشان داده‌اند. مزیت مهم یادگیری عمیق نسبت به روش‌های یادگیری ماشین کلاسیک عدم نیاز به مرحله استخراج ویژگی است. مرحله استخراج ویژگی نیاز به دانش در حوزه کاربرد و نوع داده مورد پردازش دارد، اما با استفاده از یادگیری عمیق این کار به صورت هوشمند انجام می‌شود. ضمناً، در صورت آموزش با تعداد داده بسیار زیاد، این مدل‌ها می‌توانند عملکرد بسیار قابل توجهی داشته باشند. در این راستا از شبکه‌های عصبی پیچشی^۴ (CNN) که نوع خاصی از شبکه‌های عمیق هستند به منظور تشخیص استفاده شده است.

پردازش داده‌ها به دو شکل متفاوت انجام شده است: در روش اول از تمامی کانال‌های سیگنال EEG (تعداد ۱۹ کانال) در کنار هم استفاده شده است و در روش دوم هر کانال سیگنال به صورت مجزا مورد بررسی قرار گرفته است. مدل‌ها با مجموعه داده‌ای شامل ۶۰ نفر (۲۹ نفر مبتلا به MCI و ۳۱ نفر سالم) آموزش داده شده‌اند و با استفاده از روش LOOCV به ارزیابی عملکرد مدل‌ها پرداخته شده است. نتایج حاصل از این دو روش قابل توجه بوده‌اند: به عنوان صحت بیشینه تشخیص، مقدار ۹۵ درصد برای حالت تمام کانال و مقدار ۸۵/۹۷ درصد برای حالت تک کانال و از کانال C3 بدست آمده است. ضمناً نتایج، نواحی مختلفی از مغز را به عنوان نواحی پراهمیت تر در تشخیص این بیماری معرفی می‌کنند. این نتایج نشان داده‌اند که نیم‌کره چپ مغز اهمیت بیشتری در تشخیص MCI دارد. در نهایت یک رابط کاربری گرافیکی^۵ (GUI) به منظور ارتباط با کاربر، دریافت داده و تشخیص شخص بیمار از سالم ارائه شده است.

کلیدواژه‌ها: اختلال شناختی خفیف (MCI)، یادگیری عمیق، الکتروانسفالوگرافی (EEG)، شبکه‌های عصبی پیچشی (CNN)

^۱ Mild Cognitive Impairment

^۲ Electroencephalography

^۳ Deep Learning (DL)

^۴ Convolutional Neural Networks

^۵ Graphical User Interface

فهرست مطالب

صفحه	عنوان
و.....	چکیده.....
۱.....	فصل ۱- مقدمه.....
۲.....	۱-۱- معرفی اختلال شناختی خفیف و بیان مسئله.....
۳.....	۱-۲- لزوم استفاده از ابزارهای کمک تشخیصی در پزشکی.....
۴.....	۱-۳- سیگنال‌های EEG و مزایای استفاده از آن‌ها.....
۴.....	۱-۴- پیشینه پژوهش در حوزه تشخیص اختلال شناختی خفیف با کمک روش‌های هوشمند.....
۶.....	۱-۵- راهبرد انجام پایان‌نامه.....
۷.....	۱-۶- ساختار پایان‌نامه.....
۸.....	فصل ۲- مروری بر مفاهیم و ابزار مورد نیاز.....
۹.....	۲-۱- تشریح بیماری اختلال شناختی خفیف (MCI) و مشخصات زیستی مربوط به آن.....
۱۰.....	۲-۲- یادگیری ماشین.....
۱۰.....	۲-۲-۱- یادگیری نظارت‌شده.....
۱۱.....	۲-۲-۲- چند موضوع مهم در مسائل طبقه‌بندی یادگیری نظارت‌شده.....
۱۲.....	۲-۲-۳- معرفی معیارهای ارزیابی در یادگیری نظارت‌شده.....
۱۴.....	۲-۳- یادگیری عمیق.....
۱۵.....	۲-۴- شبکه‌های عصبی پیچشی (CNN).....
۲۰.....	۲-۵- نحوه آموزش شبکه‌های عصبی.....
۲۲.....	۲-۶- جمع‌بندی فصل.....
۲۳.....	فصل ۳- رویکرد پیشنهادی پروژه.....
۲۴.....	۳-۱- داده‌ها.....

۲۴.....	۳-۱-۱- مشخصات مجموعه داده.....
۲۵.....	۳-۱-۲- نحوه تقسیم‌بندی داده‌ها برای آموزش و ارزیابی مدل‌ها.....
۲۶.....	۳-۲-۱- رویکرد اول پروژه (پردازش تمام کانال‌ها).....
۲۶.....	۳-۲-۲- ساختار پیشنهادی برای پنجره‌های زمانی ۲/۵ ثانیه.....
۲۷.....	۳-۲-۳- ساختار پیشنهادی برای پنجره‌های زمانی ۵ ثانیه.....
۲۷.....	۳-۲-۳- ساختار پیشنهادی برای پنجره‌های زمانی ۷/۵ ثانیه.....
۲۸.....	۳-۲-۴- ساختار پیشنهادی برای پنجره‌های زمانی ۱۰ ثانیه.....
۲۸.....	۳-۳- رویکرد دوم پروژه (پردازش تک کانال).....
۲۹.....	۴-۳- جمع‌بندی فصل.....
۳۰.....	فصل ۴- نتایج.....
۳۱.....	۴-۱- نتایج پردازش تمام کانال‌ها.....
۳۲.....	۴-۲- نتایج پردازش تک کانال.....
۳۳.....	۴-۳- مقایسه نتایج پروژه با یافته‌های پیشین.....
۳۴.....	۴-۴- مزایا و معایب مدل پیشنهادی پروژه.....
۳۴.....	۴-۵- رابط کاربری گرافیکی (GUI).....
۳۵.....	۴-۶- جمع‌بندی فصل.....
۳۶.....	فصل ۵- نتیجه‌گیری و پیشنهادها.....
۳۹.....	مراجع.....
۴۲.....	پیوست ۱- واژه‌نامه انگلیسی به فارسی.....

فهرست شکل‌ها

صفحه

عنوان

- شکل ۱-۱: سیستم ثبت سیگنال الکتروانسفالوگرافی..... ۴
- شکل ۱-۲: نمونه‌ای از یادگیری نظارت‌شده برای مسئله طبقه‌بندی..... ۱۰
- شکل ۲-۲: بیش‌برازش، برازش مناسب و کم‌برازش ۱۱
- شکل ۳-۲: ماتریس درهم‌ریختگی برای یک مدل ۲ کلاسی..... ۱۲
- شکل ۴-۲: تاریخچه هوش مصنوعی و زیرشاخه‌های آن، یادگیری ماشین و یادگیری عمیق..... ۱۴
- شکل ۵-۲: مقایسه یادگیری ماشین با یادگیری عمیق..... ۱۵
- شکل ۶-۲: شبکه عصبی پیچشی LeNet..... ۱۶
- شکل ۷-۲: مثالی از عملکرد لایه کانولوشن، با یک پنجره با ابعاد 3×3 ۱۶
- شکل ۸-۲: مثالی از عملکرد لایه کانولوشن، با یک پنجره با ابعاد 3×3 ۱۷
- شکل ۹-۲: مثالی از عملکرد لایه Pooling، با ابعاد 2×2 و با گام حرکت ۲..... ۱۷
- شکل ۱۰-۲: توابع فعال‌سازی پرکاربرد در شبکه‌های عصبی..... ۱۸
- شکل ۱۱-۲: ساختار یک شبکه عصبی پیچشی فرضی برای طبقه‌بندی تصاویر..... ۱۹
- شکل ۱۲-۲: یک شبکه عصبی استاندارد و شبکه عصبی پس از اعمال Dropout ۱۹
- شکل ۱۳-۲: نرمال‌سازی گاوسی..... ۲۰
- شکل ۱۴-۲: تاثیر نرخ یادگیری در روش گرادیان کاهشی..... ۲۲
- شکل ۱-۳: محل قرارگیری الکترودها بر روی مغز در سیستم ۲۰-۱۰..... ۲۴
- شکل ۲-۳: تقسیم‌بندی داده‌ها در روش LOOCV..... ۲۵
- شکل ۳-۳: ساختار شبکه پیشنهادی برای پنجره زمانی به طول ۲/۵ ثانیه..... ۲۶
- شکل ۴-۳: ساختار شبکه پیشنهادی برای پنجره زمانی به طول ۵ ثانیه..... ۲۷
- شکل ۵-۳: ساختار شبکه پیشنهادی برای پنجره زمانی به طول ۷/۵ ثانیه..... ۲۷
- شکل ۶-۳: ساختار شبکه پیشنهادی برای پنجره زمانی به طول ۱۰ ثانیه..... ۲۸
- شکل ۱-۴: محل قرارگیری کانال‌ها بر روی مغز و صحت مربوط به هریک..... ۳۳

شکل ۴-۲: رابط کاربری گرافیکی طراحی شده.....۳۵

شکل ۴-۳: نتیجه نمایش داده شده توسط رابط کاربری گرافیکی برای یک داده نمونه.....۳۵

فهرست جدول‌ها

عنوان	صفحه
جدول ۱-۳: مشخصات ثبت مجموعه داده.....	۲۴
جدول ۲-۳: مشخصات افراد شرکت‌کننده در گردآوری مجموعه داده	۲۵
جدول ۱-۴: نتایج پردازش تمام کانال‌ها.....	۳۱
جدول ۲-۴: نتایج پردازش تک کانال.....	۳۲

فصل ١ - مقدمه

۱-۱- معرفی اختلال شناختی خفیف و بیان مسئله

زوال عقل^۱ در پزشکی و روانپزشکی، اختلال مزمن و گاهی حاد فرایندهای روانی و زوال عصبی پیشرونده بوده که با تغییر شخصیت و موقعیت‌ناشناسی و اختلال در حافظه، دآوری و اندیشه همراه است. در سال ۲۰۱۵، حدود ۴۴/۴ میلیون نفر در سراسر دنیا مبتلا به نوعی از بیماری زوال عقل بودند و در هر ۴ ثانیه، یک مورد جدید تشخیص داده می‌شود [۱]. پیش‌بینی می‌شود که این تعداد به عدد ۷۵/۶ میلیون در سال ۲۰۳۰ و ۱۳۵/۵ میلیون در سال ۲۰۵۰ برسد [۱]. بیماری آلزایمر^۲ که رایج‌ترین نوع زوال عقل است، چیزی بین ۶۰٪ تا ۸۰٪ موارد زوال عقل را شامل می‌شود و ششمین علت مرگ و میر در کشور آمریکا است [۲]. بیماری آلزایمر حدود ۱۱٪ افراد بالای ۶۵ سال و ۳۲٪ افراد بالای ۸۵ سال را در سراسر دنیا تحت تاثیر قرار می‌دهد. اما متأسفانه تاکنون درمان قطعی برای بیماری آلزایمر وجود نداشته است، و موارد درمانی تنها سرعت پیشرفت بیماری را کند می‌کنند. با این توضیحات، تشخیص بیماری آلزایمر در مراحل ابتدایی آن یک مرحله کلیدی و پراهمیت در درمان آن است.

اختلال شناختی خفیف یا MCI نوعی بیماری است که منجر به کاهش توانایی‌های شناختی مانند فکر کردن، به یاد آوردن و صحبت کردن است. البته این اختلال در فعالیت‌های روزمره مشکلات قابل توجهی ایجاد نمی‌کند. در حقیقت این اختلال یک مرحله گذار بین پیری طبیعی و زوال عقل از جمله بیماری آلزایمر است. افرادی که مبتلا به MCI هستند به نسبت بالایی محتمل دچار شدن به بیماری آلزایمر یا نوعی زوال عقل هستند. در هر سال بین ۱۵ تا ۲۰ درصد از مبتلایان به MCI دچار بیماری آلزایمر می‌شوند [۳]. بنابراین تشخیص درست و به موقع MCI می‌تواند در جلوگیری از گسترش بیماری به بیماری آلزایمر نقش بسیار موثر و قابل توجهی داشته باشد.

تشخیص پزشکی MCI کار آسانی نیست. این عمل با مراحل گوناگونی از روش‌های ارزیابی پزشکی انجام می‌شود که از آن جمله‌اند [۴]:

- آزمون‌های عصبی مانند حرکت چشم‌ها، راه رفتن و حفظ تعادل، عکس‌العمل‌های غیرارادی و ...
- آزمایش خون برای بررسی موادی که بر حافظه تاثیر می‌گذارند، مانند ویتامین ب ۱۲^۳ و ...
- روش‌های تصویربرداری از مغز مانند تصویربرداری تشدید مغناطیسی^۴ و سی تی اسکن^۵
- آزمون‌های ذهنی مانند سوال در مورد نزدیکان، تاریخ و ...

^۱ Dementia

^۲ Alzheimer's Disease (AD)

^۳ B12 Vitamin

^۴ Magnetic Resonance Imaging (MRI)

^۵ CT Scan

۱-۲- لزوم استفاده از ابزارهای کمک تشخیصی در پزشکی

در سال‌های اخیر استفاده از هوش مصنوعی^۱ و یادگیری ماشین^۲ در حوزه پزشکی و به خصوص تشخیص بیماری‌ها رشد فزاینده‌ای داشته است و کمک زیادی به متخصصان این حوزه کرده است [۵]. دلایلی که می‌توان برای لزوم استفاده از این شاخه علم در حوزه تشخیص ذکر کرد عبارتند از:

- **صحت تشخیص بالا:** روش‌های مبتنی بر یادگیری ماشین به طور معمول صحت نسبتاً بالایی را در حل مسائل ارائه می‌کنند.
- **کم هزینه بودن:** در روش‌های تشخیص سنتی، شخص باید روش‌های مختلف تشخیصی را پشت سر بگذارد که معمولاً هزینه زیادی را شامل می‌شود، در حالی که با استفاده از روش‌های تشخیص خودکار این هزینه بسیار کمتر خواهد بود.
- **سریع بودن:** به دلیل استفاده از رایانه‌های پرسرعت برای تشخیص بیماری، این عمل در زمان بسیار کوتاهی انجام می‌شود.
- **کم‌اثر کردن نقش تجربه پزشک:** در روش تشخیص سنتی میزان تجربه پزشک متخصص می‌تواند اشتباهاتی در تشخیص بیماری به وجود آورد، در حالی که با استفاده از روش‌های یادگیری ماشین، این موضوع به حداقل می‌رسد.
- **کم‌اثر کردن نقش خستگی پزشک:** در روش تشخیص سنتی ممکن است پزشک متخصص در زمان‌هایی به دلیل خستگی کاری تمرکز لازم را نداشته باشد و در نتیجه تشخیص نادرست انجام شود، اما با استفاده از رایانه‌ها به منظور کمک به تشخیص بیماری، این مشکل تا حدی برطرف می‌شود.

لازم به ذکر است این ابزارها هرگز نمی‌توانند جایگزین کامل و جامعی برای پزشکان و متخصصین باشند، بلکه در کنار تجربه آنها می‌توانند کمک موثری به بهبود صحت و سرعت تشخیص بیماری‌ها بکنند.


^۱ Artificial Intelligence (AI)

^۲ Machine Learning (ML)

۳-۱- سیگنالهای EEG و مزایای استفاده از آنها

الکتروانسفالوگرافی یا EEG یک روش ثبت فعالیت الکتریکی مغز از طریق نصب الکترودهای سطحی بر روی سر و به صورت غیرتهاجمی است. در حالت کلی در یک سیستم EEG، اثر الکتریکی فعالیت نورونهای مغز از طریق الکترودهای نصب شده بر روی سر به دستگاه انتقال داده شده و پس از تقویت و حذف نویز به صورت سیگنال زمانی ثبت و نمایش داده می‌شود. سیگنال ثبت شده می‌تواند مستقیماً و یا پس از پردازش کامپیوتری توسط پزشک و یا متخصص علوم اعصاب مورد تحلیل قرار بگیرد.

مطالعات اخیر نشان داده است که سیگنالهای الکتروانسفالوگرافی EEG در تشخیص بیماری آلزایمر و اختلال شناختی خفیف قابلیت بالایی دارند. سیستم‌های ثبت EEG غیرتهاجمی، ارزان، در دسترس و قابل حمل هستند، بنابراین EEG می‌تواند نقش بسیار موثر و کارآمدی در تشخیص بیماری آلزایمر و اختلال شناختی خفیف داشته باشد. شکل ۱-۱ شمایی از سیستم ثبت EEG را نشان می‌دهد.



شکل ۱-۱: سیستم ثبت سیگنال الکتروانسفالوگرافی [۶]

۴-۱- پیشینه پژوهش در حوزه تشخیص اختلال شناختی خفیف با کمک روش‌های هوشمند

مطالعات و پژوهش‌ها در حوزه تشخیص MCI با کمک روش‌های هوش مصنوعی شامل دو شاخه می‌شود:

- رویکردهای مبتنی بر روش‌های کلاسیک یادگیری ماشین
- رویکردهای مبتنی بر روش‌های یادگیری عمیق

در شاخه اول به دلیل استفاده از روش‌های کلاسیک یادگیری ماشین، نیاز بسیاری به استخراج ویژگی‌های معنادار از سیگنال‌ها وجود دارد. این مرحله استخراج ویژگی^۱ خود مرحله نسبتاً زمانبری است که نیاز به متخصصین این حوزه دارد.

در شاخه دوم که مبتنی بر روش‌های یادگیری عمیق است، نیاز کمتری به مرحله استخراج ویژگی وجود دارد، با این حال در بسیاری از مطالعات و پژوهش‌های قبلی ابتدا ویژگی‌هایی از سیگنال‌ها استخراج شده‌اند و این ویژگی‌ها به عنوان ورودی شبکه‌های عمیق مورد استفاده قرار گرفته‌اند. این ویژگی‌ها با کمک روش‌های تبدیل حوزه زمان - فرکانس مانند تبدیل موجک^۲، تبدیل فوریه^۳ و همچنین اسپکتروگرام^۴ محاسبه شده‌اند. بنابراین کمتر پیش آمده است که از داده‌های خام به عنوان ورودی مدل استفاده شود. در ادامه مروری مختصر بر پیشینه مسئله تشخیص MCI بر اساس سیگنال‌های EEG و با کمک روش‌های یادگیری عمیق خواهیم داشت:

■ در مقاله‌ای که در سال ۲۰۱۶ منتشر شده است، نویسندگان یک شبکه عصبی پیچشی با دو لایه پیشنهاد کرده‌اند که ورودی آن ویژگی‌های استخراج شده از منحنی‌های زمان - فرکانس است که با کمک تبدیل موجک پیوسته محاسبه شده‌اند. مجموعه داده مورد استفاده در این پژوهش شامل ۲۳ نفر سالم، ۲۳ نفر مبتلا به MCI و ۲۳ نفر مبتلا به بیماری آلزایمر است. در طبقه‌بندی بین دو کلاس سالم و MCI صحت ۸۵ درصد گزارش شده است [۷].

■ در مقاله دیگری که در سال ۲۰۱۸ منتشر شده است، نویسندگان یک شبکه عصبی عمیق با ۴ لایه پنهان پیشنهاد کرده‌اند که ورودی آن ویژگی‌های استخراج شده از توان باندهای مختلف فرکانسی سیگنال‌های EEG هستند. مجموعه داده مورد استفاده در این پژوهش شامل ۱۰ نفر سالم و ۱۰ نفر مبتلا به MCI است. صحت طبقه‌بندی ۷۵ درصد گزارش شده است [۸].

■ در مقاله دیگری که در سال ۲۰۱۹ منتشر شده است، نویسندگان یک شبکه عصبی پیچشی با ۱ لایه پنهان پیشنهاد کرده‌اند که ورودی آن تصاویر پریدوگرام^۵ هستند که از پردازش سیگنال‌های EEG بدست آمده‌اند. مجموعه داده مورد استفاده در این پژوهش شامل ۶۳ نفر سالم، ۶۳ نفر مبتلا به MCI و ۶۳ نفر مبتلا به بیماری آلزایمر است. در طبقه‌بندی بین دو کلاس سالم و MCI صحت ۹۲ درصد گزارش شده

^۱ Feature Extraction

^۲ Wavelet Transform

^۳ Fourier Transform

^۴ Spectrogram

^۵ Periodogram

است [۹].

■ در یکی از جدیدترین مقالات که در سال ۲۰۲۱ منتشر شده است، نویسندگان ابتدا منحنی‌های زمان – فرکانس هر کانال سیگنال EEG را با کمک تبدیل موجک پیوسته محاسبه کرده و از کنار هم قرار دادن آنها تصاویری به عنوان ورودی ساخته شده است. سپس با این داده‌ها و با کمک روش انتقال یادگیری^۱ شبکه معروف AlexNet آموزش داده شده و مورد استفاده قرار گرفته است. مجموعه داده مورد استفاده در این پژوهش شامل ۵۲ نفر سالم، ۳۷ نفر مبتلا به MCI و ۵۲ نفر مبتلا به بیماری آلزایمر است. در طبقه‌بندی بین دو کلاس سالم و MCI صحت ۹۸/۳ درصد گزارش شده است [۱۰].

۱-۵- راهبرد انجام پایان‌نامه

در این پایان‌نامه با استفاده از یک مجموعه داده^۲ که در دسترس عموم است و شامل سیگنال‌های EEG تعداد ۶۰ شخص اعم از مبتلا به MCI و سالم می‌شود، مدل‌هایی مبتنی بر یادگیری عمیق و شبکه‌های عصبی پیچشی به منظور تشخیص فرد بیمار از سالم آموزش داده شده‌اند. در نهایت با کمک روش ارزیابی خاصی به محاسبه میزان صحت هر مدل پرداخته شده است.

به طور خلاصه، ابتدا سیگنال‌های EEG به بازه‌های زمانی کوتاهی تقسیم شده‌اند، و سپس مدل‌ها با این داده‌های خام آموزش دیده‌اند. در مرحله اول پروژه از همگی کانال‌های سیگنال EEG برای آموزش مدل‌ها استفاده شده است، اما در مرحله دوم از هر کانال به طور مجزا برای تشخیص و آموزش مدل استفاده شده است.

نتایج به دست آمده از هر دو روش قابل قبول و رضایت بخش هستند. ضمناً با کمک روش دوم می‌توان نواحی مختلف مغز را بر اساس قابلیت ایجاد تمایز در تشخیص بیماری تفکیک کرد.

در پایان یک رابط کاربری گرافیکی به منظور ارتباط با کاربر و تشخیص بیمار از سالم طراحی شده است.

^۱ Transfer Learning

^۲ Dataset

۱-۶- ساختار پایان نامه

این پایان نامه شامل ۵ فصل و ۱ پیوست است. در فصل ۲ به معرفی مفاهیم و ابزار مورد استفاده در پروژه پرداخته می شود. در فصل ۳ رویکرد پروژه و نحوه حل مسئله تشریح می شود و در فصل ۴ به بحث درباره نتایج و مقایسه بین روش این پروژه با روش های دیگر پرداخته می شود. نهایتاً در فصل ۵ به نتیجه گیری و ارائه پیشنهاد برای کارهای آینده پرداخته خواهد شد.

مراجع بعد از آخرین فصل ذکر شده اند و در پیوست اول یک واژه نامه فارسی - انگلیسی قرار داده شده است.

فصل ۲- مروری بر مفاهیم و ابزار مورد نیاز

۲-۱- تشریح بیماری اختلال شناختی خفیف (MCI) و مشخصات زیستی مربوط به آن

همانطور که در بخش مقدمه اشاره شد، اختلال شناختی خفیف نوعی بیماری است که منجر به کاهش توانایی‌های شناختی مانند فکر کردن، به یاد آوردن و صحبت کردن است. البته این اختلال در فعالیت‌های روزمره مشکلات قابل توجهی ایجاد نمی‌کند. در حقیقت این اختلال یک مرحله گذار بین پیری طبیعی و زوال عقل از جمله بیماری آلزایمر است. افرادی که مبتلا به MCI هستند به نسبت بالایی محتمل دچار شدن به بیماری آلزایمر یا نوعی زوال عقل هستند.

شواهد موجود نشان می‌دهد که MCI اغلب، اما نه همیشه، از درجه کمتری از همان تغییرات مغزی مشاهده می‌شود که در بیماری آلزایمر یا سایر اشکال زوال عقل دیده می‌شود. برخی از این تغییرات در مطالعات کالبد شکافی افراد مبتلا به MCI شناسایی شده است. این تغییرات شامل موارد زیر است [۱۱]:

- توده‌های غیرطبیعی پروتئین بتا آمیلوئید^۱ (پلاک) و پروتئین میکروسکوپی تاو^۲ که مشخصه بیماری آلزایمر است.
- اجسام لوی^۳، که توده‌های میکروسکوپی پروتئین دیگری در ارتباط با بیماری پارکینسون^۴ هستند.
- سگته‌های کوچک یا کاهش جریان خون از طریق رگ‌های خونی مغز

مطالعات تصویربرداری از مغز نشان می‌دهد که تغییرات زیر ممکن است با MCI مرتبط باشد [۱۱]:

- تحلیل رفتن هیپوکامپ^۵ (یک قسمت از مغز که برای حافظه مهم است)
- بزرگ شدن فضای پر از مایعات مغز
- کاهش استفاده از گلوکز، قندی که منبع اصلی انرژی سلول‌ها است، در مناطق اصلی مغز

^۱ Amyloid beta

^۲ Tau Proteins

^۳ Lewy Bodies

^۴ Parkinson's Disease (PD)

^۵ Hippocampus

۲-۲- یادگیری ماشین

در علم یادگیری ماشین که زیرمجموعه‌ای از علم هوش مصنوعی است، به موضوع طراحی ماشین‌هایی پرداخته می‌شود که با استفاده از مثال‌های داده شده به آن‌ها و تجربیات خودشان، بیاموزند. در واقع، در این علم تلاش می‌شود تا با بهره‌گیری از الگوریتم‌ها، یک ماشین به شکلی طراحی شود که بدون آنکه صراحتاً برنامه‌ریزی و تک تک اقدامات به آن دیکته شود بتواند بیاموزد و عمل کند. در یادگیری ماشین، به جای برنامه‌نویسی همه چیز، داده‌ها به یک الگوریتم عمومی داده می‌شوند و این الگوریتم است که براساس داده‌هایی که به آن داده شده منطق خود را می‌سازد.


یک نوع مهم از مسائلی که الگوریتم‌های یادگیری ماشین قادر به حل آن هستند، مسائل طبقه‌بندی^۱ است. در این نوع مسائل هدف جداسازی داده‌ها بر اساس گروه یا طبقه مخصوص آنهاست. مثال‌هایی از مسائل طبقه‌بندی عبارتند از: تشخیص و طبقه‌بندی انواع حیوانات، گیاهان و خودروها بر اساس تصویر آنها، تشخیص افراد بیمار از سالم، تشخیص ایمیل معتبر از نامعتبر و مثال‌های متعدد دیگر.

۲-۲-۱- یادگیری نظارت شده

مسائل طبقه‌بندی در حوزه یادگیری نظارت‌شده^۲ از یادگیری ماشین قرار می‌گیرند.

یادگیری نظارت شده نوعی از یادگیری مربوط به یادگیری ماشین است که در آن ورودی و خروجی مشخص است و به اصطلاح ناظری وجود دارد که اطلاعاتی را در اختیار یادگیرنده قرار می‌دهد، و به این ترتیب سیستم سعی می‌کند تا تابعی را از ورودی به خروجی فرا گیرد.

در مسائل طبقه‌بندی خروجی‌ها همان برجسب (شماره کلاس) داده‌ها است که برای آموزش دیدن در اختیار مدل قرار می‌گیرند. شکل ۲-۱ یک مثال فرضی از یادگیری نظارت‌شده را نشان می‌دهد.



شکل ۲-۱: نمونه‌ای از یادگیری نظارت‌شده برای مسئله طبقه‌بندی [۱۲]

^۱ Classification

^۲ Supervised Learning

۲-۲-۲- چند موضوع مهم در مسائل طبقه‌بندی یادگیری نظارت‌شده

- در مسائل یادگیری نظارت‌شده داده‌ها را عمدتاً به دو قسمت داده‌های آموزشی^۱ و ارزیابی^۲ تقسیم می‌کنند. از داده‌های آموزشی برای یادگیری طبقه‌بند و از داده‌های ارزیابی برای آزمون و محاسبه صحت طبقه‌بند استفاده می‌شود.


- تعریف مفهوم بیش‌برازش^۳:

در یادگیری ماشین، هنگامی که داده‌های آموزشی به خوبی فرا گرفته شوند اما صحت روی داده‌های ارزیابی کم باشد اصطلاحاً گفته می‌شود که مدل دچار بیش‌برازش شده است. این موضوع یعنی مدل قابلیت تعمیم^۴ ندارد و صرفاً داده‌های آموزشی را حفظ کرده است. این موضوع به دلیل پیچیدگی بیش از حد مدل رخ می‌دهد.

- تعریف مفهوم کم‌برازش^۵:

زمانی که داده‌های آموزشی به خوبی فرا گرفته نشوند اصطلاحاً گفته می‌شود که مدل دچار کم‌برازش شده است. این موضوع به دلیل سادگی بیش از حد مدل رخ می‌دهد.

مفهوم شهودی بیش‌برازش و کم‌برازش در شکل ۲-۲ نشان داده شده است:



شکل ۲-۲: بیش‌برازش (شکل سمت راست)، برآزش مناسب (شکل وسط)،

کم‌برازش (شکل سمت چپ) [۱۳]

^۱ Training Data

^۲ Test Data

^۳ Overfitting

^۴ Generality

^۵ Underfitting

۳-۲-۲- معرفی معیارهای ارزیابی در یادگیری نظارت شده

پس از اینکه یک مدل آموزش داده شد، عملکرد این مدل باید روی داده‌های ارزیابی مورد بررسی قرار گیرد. در یادگیری نظارت شده از یک ماتریس به نام ماتریس درهم‌ریختگی^۱ برای محاسبه صحت مدل استفاده می‌شود. این ماتریس در واقع جدولی است که نشان می‌دهد چه تعداد از داده‌ها به درستی در هر کلاس قرار گرفته‌اند و چه تعداد از داده‌ها در کلاس نادرست.

ساختار این ماتریس برای یک مدل ۲ کلاسی در شکل ۳-۲ قابل مشاهده است:

		Predicted Values	
		Negative	Positive
Actual Values	Negative	TN	FP
	Positive	FN	TP

شکل ۳-۲: ماتریس درهم‌ریختگی برای یک

مدل ۲ کلاسی [۱۴]

این ماتریس شامل چهار مقدار مهم است:

- **TP (True Positive):** تعداد داده‌هایی که در واقعیت عضو کلاس مثبت هستند و مدل هم همین را پیش‌بینی کرده است.
- **TN (True Negative):** تعداد داده‌هایی که در واقعیت عضو کلاس منفی هستند و مدل هم همین را پیش‌بینی کرده است.
- **FP (False Positive):** تعداد داده‌هایی که در واقعیت عضو کلاس منفی هستند ولی مدل آن‌ها را به اشتباه عضو کلاس مثبت پیش‌بینی کرده است.
- **FN (False Negative):** تعداد داده‌هایی که در واقعیت عضو کلاس مثبت هستند ولی مدل آن‌ها را به اشتباه عضو کلاس منفی پیش‌بینی کرده است.

با دانستن این چهار مقدار، می‌توان چندین معیار ارزیابی برای مدل محاسبه کرد:

^۱ Confusion Matrix

- **صحت^۱:** این معیار برابر است با نسبت تعداد داده‌هایی که درست طبقه‌بندی شده‌اند به تعداد کل داده‌ها و یک ارزیابی کلی از مدل است. رابطه (۱-۲) فرمول مربوط به محاسبه صحت را نشان می‌دهد:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (1-2)$$

- **دقت^۲:** این معیار برابر است با نسبت تعداد داده‌هایی که به درستی در کلاس مثبت قرار گرفته‌اند به تعداد داده‌هایی که توسط مدل در کلاس مثبت قرار گرفته‌اند. فرض کنیم مدلی برای تشخیص سرطان وجود دارد و این مدل صحت پایینی داشته باشد. نتیجه این امر این است که این مدل، بیماری بسیاری از افراد را به اشتباه سرطان تشخیص می‌دهد. این اتفاق باعث ایجاد نگرانی زیاد و هزینه‌های گزاف برای بیمار خواهد بود. رابطه (۲-۲) فرمول مربوط به محاسبه دقت را نشان می‌دهد:

$$Precision = \frac{TP}{TP + FP} \quad (2-2)$$

- **پوشش^۳ یا حساسیت^۴:** این معیار برابر است با نسبت تعداد داده‌هایی که به درستی در کلاس مثبت قرار گرفته‌اند به تعداد داده‌هایی که در واقعیت در کلاس مثبت قرار دارند. فرض کنیم مدلی برای تشخیص بیماری کرونا وجود دارد. اگر این مدل پوشش پایینی داشته باشد بدین معنی است که این مدل افراد زیادی را که آلوده به این بیماری هستند سالم در نظر می‌گیرد و این فاجعه است. رابطه (۳-۲) فرمول مربوط به محاسبه پوشش را نشان می‌دهد:

$$Recall = \frac{TP}{TP + FN} \quad (3-2)$$

- **اختصاصیت^۵:** این معیار برابر است با نسبت تعداد داده‌هایی که به درستی در کلاس منفی قرار گرفته‌اند به تعداد داده‌هایی که در واقعیت در کلاس منفی قرار دارند. رابطه (۴-۲) فرمول مربوط به محاسبه پوشش را نشان می‌دهد:

^۱ Accuracy

^۲ Precision

^۳ Recall

^۴ Sensitivity

^۵ Specificity

$$Specificity = \frac{TN}{TN + FP} \quad (۴-۲)$$


- **F1-Score**: این معیار میانگین همساز^۱ دو معیار صحت و پوشش است و در کل معیار مناسب و نسبتاً جامعی است. رابطه (۵-۲) فرمول مربوط به محاسبه F1-Score را نشان می‌دهد:

$$F1\ Score = 2 * \frac{Precision * Recall}{Precision + Recall} \quad (۵-۲)$$

۳-۲- یادگیری عمیق

یادگیری عمیق زیرشاخه‌ای از روش‌های یادگیری ماشین است که در سال‌های اخیر قدرت فراوانی را از خود نشان داده است. در روش‌های یادگیری عمیق که همگی مبتنی بر شبکه‌های عصبی مصنوعی^۲ هستند، تعداد زیادی واحدهای پردازشی که به نورون^۳ معروف هستند در لایه‌های متعدد کنار هم قرار می‌گیرند و عملیات پردازش و طبقه‌بندی را انجام می‌دهند. مزیت مهم استفاده از یادگیری عمیق این است که در مقایسه با روش‌های کلاسیک یادگیری ماشین، معمولاً نیازی به مرحله استخراج ویژگی ندارد و حتی در بعضی موارد می‌تواند با داده‌های خام نیز آموزش ببیند و در عین حال دقت بسیار بالایی داشته باشد. مرحله استخراج ویژگی خود حوزه خاصی از علوم داده است که بنا به انواع مختلف داده‌ها که از نوع تصویری باشند، از نوع سیگنال زمانی باشند یا غیره روش‌ها و رویکردهای مخصوص به خود را دارد، و متخصصینی تنها در این زمینه فعالیت می‌کنند.

شکل ۴-۲ شمایی از رابطه یادگیری عمیق با یادگیری ماشین و هوش مصنوعی و همچنین تاریخچه فراگیر شدن آنها را نشان می‌دهد:




شکل ۴-۲: تاریخچه هوش مصنوعی و زیرشاخه‌های آن، یادگیری ماشین و یادگیری عمیق [۱۵]

^۱ Harmonic Mean

^۲ Artificial Neural Networks

^۳ Neuron

شکل ۲-۵ تفاوت یادگیری عمیق با یادگیری ماشین کلاسیک را به تصویر کشیده است:



شکل ۲-۵: مقایسه یادگیری ماشین با یادگیری عمیق [۱۶]

یادگیری عمیق روش‌ها و مدل‌های مختلفی دارد. از مشهورترین و پرکاربردترین آنها می‌توان این موارد را نام برد:

- شبکه‌های عصبی عمیق^۱
- شبکه‌های عصبی پیچشی (CNN)
- شبکه‌های عصبی بازگشتی^۲ (RNN)

با توجه به اینکه در این پایان‌نامه از شبکه‌های عصبی پیچشی استفاده شده است، در ادامه به معرفی این نوع از شبکه‌های عمیق خواهیم پرداخت.

۲-۴- شبکه‌های عصبی پیچشی (CNN)

شبکه‌های عصبی پیچشی یکی از قدرتمندترین مدل‌های یادگیری عمیق هستند. این نوع شبکه‌ها در زمینه‌های مختلف کاربردهای بسیاری دارند از جمله: طبقه‌بندی تصاویر، بخش‌بندی تصاویر^۳، پردازش زبان طبیعی^۴، رابط‌های مغز و کامپیوتر^۵ و بسیاری کاربردهای دیگر.

^۱ Deep Neural Networks


^۲ Recurrent Neural Networks

^۳ Image Segmentation

^۴ Natural Language Processing

^۵ Brain-Computer Interface (BCI)


یکی از اولین موارد استفاده از شبکه‌های عصبی پیچشی که موفقیت آمیز بود شبکه‌ای به نام LeNet بود که در سال ۱۹۸۹ برای تشخیص حروف دستنویس توسعه یافت. شکل ۲-۶ ساختار شبکه LeNet را نشان می‌دهد. [۱۷]



شکل ۲-۶: شبکه عصبی پیچشی LeNet [۱۷]

شبکه‌های عصبی پیچشی به طور کلی از کنار هم قرار گرفتن تعداد زیادی لایه‌های کانولوشن^۱، Pooling و تمام متصل در کنار توابع فعال‌سازی^۲ تشکیل می‌شوند. در ادامه هر یک از این موارد به تفصیل شرح داده می‌شود:

- **لایه کانولوشن:** این لایه پنجره‌ای متشکل از وزن‌های عددی (نورون‌ها) است. این پنجره بر روی داده ورودی به لایه می‌لغزد و در هر ناحیه با ضرب نظیر به نظیر اعداد در هم و نهایتاً جمع مقادیر، مقدار خروجی حاصل می‌شود. لازم به ذکر است که در مرحله آموزش شبکه، مقادیر عددی این پنجره‌ها هستند که بهینه می‌شوند. ضمناً به این پنجره‌ها کرنل^۴ یا فیلتر^۵ نیز گفته می‌شود. شکل‌های ۲-۷ و ۲-۸ نحوه عملکرد این لایه را با یک مثال عددی نشان می‌دهند.



شکل ۲-۷: مثالی از عملکرد لایه کانولوشن، با یک پنجره با ابعاد ۳*۳ [۱۸]


^۱ Convolution Layer

^۲ Activation Function

^۳ Weight

^۴ Kernel

^۵ Filter



شکل ۲-۸: مثالی از عملکرد لایه کانولوشن، با یک پنجره با ابعاد 3×3 (همان شکل ۷-۲ که پنجره به سمت راست لغزیده است).


[۱۸]

مشابه با شکل‌های ۷-۲ و ۸-۲ پنجره در نواحی مختلف حرکت می‌کند و نهایتاً خروجی ساخته می‌شود.

پنجره‌ها (کرنل‌ها) در لایه‌های کانولوشن دارای مشخصاتی هستند از جمله:

- سایز پنجره
- گام^۱ حرکت (برای مثال در تصاویر ۷-۲ و ۸-۲ گام حرکت برابر با یک است).
- حاشیه‌گذاری^۲: معمولاً برابر با صفر در نظر گرفته می‌شود. در غیر این صورت داده ورودی در حاشیه‌ها قبل از عبور از پنجره گسترش می‌یابد.

- **لایه Pooling**: این لایه نیز نوعی پنجره لغزان است، اما تفاوت آن با لایه کانولوشن در این است که خود شامل وزن‌های عددی نیست، در نتیجه پارامتری برای بهینه شدن در حین آموزش شبکه ندارد. در واقع این لایه وظیفه کاهش ابعاد داده‌ها را بر عهده دارد و می‌تواند در نواحی‌ای که می‌لغزد مقدار بیشینه یا میانگین مقادیر ورودی در آن ناحیه را در خروجی قرار دهد. شکل ۲-۹ نمونه‌ای از عملکرد لایه Pooling را به نمایش می‌گذارد.



شکل ۲-۹: مثالی از عملکرد لایه Pooling، با ابعاد 2×2 و گام حرکت ۲ (شکل سمت راست: میانگین، شکل سمت چپ: بیشینه) [۱۸]


^۱ Stride

^۲ Padding

لازم به ذکر است سه مشخصه سائز، گام حرکت و حاشیه‌گذاری برای لایه Pooling نیز وجود دارند.

- **لایه تمام متصل^۱:** پس از اینکه داده‌های ورودی از تعدادی لایه کانولوشن و Pooling عبور کردند، به صورت خطی و تک بعدی در می‌آیند و سپس با عبور از چند لایه نورونی خطی (مشابه شبکه عصبی معمولی)، خروجی محاسبه می‌شود. این لایه‌های نورونی، لایه تمام متصل نامیده می‌شوند. وزن‌های این لایه‌ها نیز در هنگام آموزش شبکه قابل بهینه‌سازی هستند.


- **توابع فعال‌سازی:** معمولاً بعد از لایه‌های کانولوشن و تمام متصل، داده‌ها از توابعی به نام توابع فعال‌سازی عبور می‌کنند. بخشی از قدرت شبکه‌های عصبی مربوط به همین توابع است، زیرا قابلیت شناسایی الگوهای غیرخطی را به الگوریتم می‌دهند. شکل ۲-۱۰ چند نمونه از مهم‌ترین و پرکاربردترین توابع فعال‌سازی را نشان می‌دهد.



شکل ۲-۱۰: توابع فعال‌سازی پر کاربرد در شبکه‌های عصبی [۱۹]

^۱ Fully Connected Layer


شکل ۱۱-۲ یک شبکه عصبی پیچشی فرضی را که متشکل از لایه‌های کانولوشن، Pooling، تمام متصل و توابع فعال‌سازی است نشان می‌دهد:



شکل ۱۱-۲: ساختار یک شبکه عصبی پیچشی فرضی برای طبقه‌بندی تصاویر [۲۰]

در کنار موارد قبل که ساختار اصلی شبکه‌های عصبی پیچشی را تشکیل می‌دهند، از چند نوع لایه دیگر برای بهبود عملکرد شبکه استفاده می‌شود. در ادامه به این موارد می‌پردازیم:

- **لایه Dropout:** استفاده از Dropout یک روش برای کاهش بیش‌برازش در شبکه‌های عصبی است. در این روش، درصدی از نورون‌های یک شبکه عصبی هر بار به صورت تصادفی از روند یادگیری حذف می‌شود. این کار به جلوگیری از پیچیده شدن بیش از حد مدل کمک می‌کند و عمومیت مدل را بهبود می‌بخشد. شکل ۱۲-۲ یک شبکه عصبی را قبل و بعد از اعمال Dropout نشان می‌دهد:




شکل ۱۲-۲: یک شبکه عصبی استاندارد (شکل سمت چپ) و شبکه عصبی پس از اعمال Dropout (شکل سمت راست) [۲۱]

▪ **لایه Batch Normalization:** این لایه معمولاً بعد از لایه‌های کانولوشن و تمام متصل قرار می‌گیرد و وظیفه آن استانداردسازی داده‌ها^۱ است. در استانداردسازی با ایجاد تغییراتی بر روی داده‌ها آن‌ها را به بازه مشخصی می‌بریم تا مقیاس عددی داده‌ها تاثیری در نتیجه نداشته باشد. یکی از پرکاربردترین روش‌های استانداردسازی، نرمال‌سازی گاوسی^۲ است که با کمک آن، داده‌ها دارای میانگین صفر و واریانس یک می‌شوند. فرمول این روش در رابطه (۶-۲) آورده شده است:

$$X_{new} = \frac{X - \mu}{\sigma} \quad (۶-۲)$$

در رابطه (۶-۲) X برداری متشکل از داده‌های اولیه، μ میانگین داده‌های بردار X ، σ انحراف معیار داده‌های بردار X و X_{new} بردار نرمال‌شده است.

شکل ۲-۱۳ شمایی از نرمال‌سازی گاوسی را نشان می‌دهد:



شکل ۲-۱۳: نرمال‌سازی گاوسی [۲۲]

۲-۵- نحوه آموزش شبکه‌های عصبی

به طور کلی در مسائل یادگیری ماشین هدف کمینه‌سازی تابعی به نام تابع هزینه^۳ است. در حقیقت مسائل یادگیری ماشین نوعی مسائل بهینه‌سازی هستند.

آموزش شبکه‌های عصبی شامل دو قسمت انتشار رو به جلو^۴ و انتشار رو به عقب^۵ می‌شود. در مرحله انتشار رو به جلو ابتدا داده‌ها در وزن‌های شبکه عصبی ضرب شده و خروجی محاسبه می‌شود. سپس خروجی بدست آمده با

^۱ Data Standardization

^۲ Gaussian Normalization

^۳ Cost Function

^۴ Forward Propagation

^۵ Backward Propagation

خروجی مطلوب مقایسه شده و مقدار تابع هزینه محاسبه می‌شود. در مسائل طبقه‌بندی تابع هزینه از نوع آنتروپی متقابل^۱ در نظر گرفته می‌شود که فرمول آن در رابطه (۷-۲) قابل مشاهده است:

$$J = -\frac{1}{m} \sum_{i=1}^m [y_i \cdot \log y_i + (1 - y_i) \cdot \log (1 - y_i)] \quad (۷-۲)$$

در رابطه (۷-۲) J تابع هزینه، m تعداد داده‌ها و y_i خروجی (کلاس) مربوط به داده i ام است.

سپس در مرحله انتشار رو به عقب، بر اساس قاعده زنجیره‌ای و با توجه به اینکه مقدار تابع هزینه تابعی از وزن‌ها است، مقدار مشتق تابع هزینه نسبت به وزن‌ها محاسبه می‌شود. در ادامه با کمک روش‌های بهینه‌سازی عددی مانند گرادیان کاهشی^۲، آدابوست^۳ و آدام^۴ مقادیر وزن‌ها بهینه می‌شوند.

روش گرادیان کاهشی یکی از پایه‌ای‌ترین روش‌های بهینه‌سازی عددی است. رابطه (۸-۲) فرمول این روش را نشان می‌دهد:

$$\theta := \theta - \alpha \frac{\partial J(\theta)}{\partial \theta} \quad (۸-۲)$$

در رابطه (۸-۲) θ وزن شبکه عصبی، J تابع هزینه و α مقداری به نام نرخ یادگیری^۵ است. این رابطه مبتنی بر یک اصل ساده است: با حرکت در خلاف جهت مشتق تابع به سوی مقدار بهینه تابع حرکت خواهیم کرد.

نرخ یادگیری میزان حرکت به سوی نقطه بهینه تابع را کنترل می‌کند. اگر این عدد مقدار بزرگی داشته باشد ممکن است واگرایی رخ دهد و هرگز به نقطه بهینه دست نیابیم. همچنین اگر مقدار کوچکی داشته باشد حرکت به سوی نقطه بهینه کند خواهد بود و زمان زیادی طول می‌کشد تا به نقطه بهینه دست یابیم.

شکل ۱۴-۲ روش گرادیان کاهشی و تاثیر نرخ یادگیری در روند آن را نشان می‌دهد:


^۱ Cross Entropy

^۲ Gradient Descent

^۳ AdaBoost

^۴ Adam

^۵ Learning Rate



شکل ۲-۱۴: تاثیر نرخ یادگیری در روش گرادیان کاهشی (شکل راست: نرخ یادگیری بزرگ، شکل وسط: نرخ یادگیری مناسب، شکل چپ: نرخ یادگیری کوچک) [۲۳]

لازم به ذکر است که روش‌های دیگر بهینه‌سازی مانند آدابوست و آدام نیز بر پایه روش گرادیان کاهشی بنا شده‌اند.

۲-۶- جمع‌بندی فصل

در این فصل ابتدا درباره بیماری MCI و دلایل زیستی بروز آن بحث شد. در ادامه به معرفی ابزارهای موردنیاز در این پروژه یعنی مفاهیم یادگیری ماشین، یادگیری عمیق و شبکه‌های عصبی پیچشی پرداخته شد. سپس لایه‌های مختلف تشکیل‌دهنده شبکه‌های عصبی پیچشی همراه با جزئیات معرفی شدند و در نهایت روش آموزش و بهینه‌سازی شبکه‌های عصبی شرح داده شد.

با دانستن این مفاهیم، در فصل بعد به تشریح رویکرد پروژه و ارائه مدل پیشنهادی آن می‌پردازیم.

فصل ۳- رویکرد پیشنهادی پروژه

۳-۱- داده‌ها


۳-۱-۱- مشخصات مجموعه داده

مجموعه داده استفاده شده در این پروژه با همکاری دانشگاه علوم پزشکی اصفهان و بیمارستان نور اصفهان گردآوری شده و در دسترس عموم قرار گرفته است [۲۴].

این مجموعه داده شامل ۶۰ نفر است که شامل ۳۱ نفر سالم و ۲۹ نفر مبتلا به MCI است. تمامی شرکت‌کنندگان بیشتر از ۵۵ سال سن داشته و دارای تحصیلات ابتدایی یا بالاتر بوده‌اند [۲۴].

ثبت تمامی داده‌ها در حالت استراحت افراد با چشمان بسته و در هنگام صبح در یک اتاق آرام انجام شده است. گردآوری داده‌های EEG با تعداد ۱۹ کانال (الکتروود) و بر اساس سیستم بین‌المللی ۱۰-۲۰ انجام شده است [۲۴].

شکل ۳-۱ محل قرارگیری الکتروودها بر روی مغز و نام آنها را در سیستم ۱۰-۲۰ نشان می‌دهد:



شکل ۳-۱: محل قرارگیری الکتروودها بر روی مغز در سیستم ۱۰-۲۰ [۲۵]

فرکانس نمونه‌برداری سیگنال‌ها ۲۵۶ هرتز بوده و از هر شخص به طور تقریبی ۳۰ دقیقه ثبت داده انجام شده است. در جدول ۳-۱ مشخصات ثبت مجموعه داده قابل مشاهده است:

جدول ۳-۱: مشخصات ثبت مجموعه داده

فرکانس نمونه‌برداری (هرتز)	۲۵۶
زمان ثبت داده برای هر نفر (دقیقه)	(تقریباً) ۳۰
تعداد کانال سیگنال EEG	۱۹ (بر اساس سیستم ۱۰-۲۰)

جدول ۲-۳ مشخصات افراد شرکت کننده در گردآوری مجموعه داده را نشان می دهد:

جدول ۲-۳: مشخصات افراد شرکت کننده در گردآوری مجموعه داده


مشخصات	سالم	MCI
تعداد افراد (نفر)	۳۱	۲۹
سن (سال)	$63/8 \pm 4/3$	$65/7 \pm 4/9$
تحصیلات (سال)	$8/7 \pm 2/3$	$8/3 \pm 1/8$

۲-۱-۳- نحوه تقسیم بندی داده ها برای آموزش و ارزیابی مدل ها

در این پروژه سیگنال های زمانی EEG به پنجره های زمانی کوتاه تقسیم بندی شده اند. برای این منظور ۴ حالت مختلف از تقسیم بندی داده ها در نظر گرفته شده است: بازه های زمانی ۲/۵ ثانیه، ۵ ثانیه، ۷/۵ ثانیه و ۱۰ ثانیه. برای هر حالت یک مدل بهینه ارائه شده است.

تقسیم بندی داده ها برای آموزش و ارزیابی بر اساس روش $LOOCV^1$ بوده است. در این روش داده های مربوط به یک نمونه (شخص) به عنوان داده ارزیابی و دیگر داده ها به عنوان داده آموزش در نظر گرفته می شوند. این کار برای تمام نمونه ها (اشخاص) انجام می شود. در حقیقت اگر تعداد نمونه ها (اشخاص) را n فرض کنیم، مدل را به تعداد n بار آموزش می دهیم. در نهایت میانگین دقت آنها به عنوان دقت مدل در نظر گرفته می شود.

شکل ۲-۳ شمایی از روش $LOOCV$ نشان می دهد:



شکل ۲-۳: تقسیم بندی داده ها در روش $LOOCV$ [۲۶]

¹ Leave-One-Out Cross-Validation


۳-۲- رویکرد اول پروژه (پردازش تمام کانال‌ها)

در انجام این پروژه و برای حل مسئله از شبکه‌های عصبی پیچشی یک بعدی استفاده شده است.

در مرحله اول پروژه ابتدا با چهار حالت مختلف تقسیم‌بندی زمانی داده‌ها، شبکه‌هایی را با تمامی کانال‌های سیگنال EEG در کنار هم (تعداد ۱۹ کانال) آموزش دادیم. برای هر چهار حالت مختلف تقسیم‌بندی داده‌ها (بازه‌های زمانی مختلف) یک ساختار بهینه بدست آمده است. در ادامه مشخصات شبکه پیشنهادی برای هر حالت را معرفی خواهیم کرد. لازم به ذکر است پیاده‌سازی و آموزش مدل‌ها با زبان برنامه‌نویسی پایتون^۱ و با کمک کتابخانه‌های TensorFlow و Keras انجام شده است. ضمناً نتایج این شبکه‌ها در فصل ۵ مورد بحث قرار خواهند گرفت.

۳-۲-۱- ساختار پیشنهادی برای پنجره‌های زمانی ۲/۵ ثانیه

شبکه پیشنهادی برای این بخش شامل ۳ لایه کانولوشن است و در مجموع حدود ۴۷۷ هزار پارامتر قابل آموزش دارد. ساختار این شبکه با جزئیات در شکل ۳-۳ قابل مشاهده است:




شکل ۳-۳: ساختار شبکه پیشنهادی برای پنجره زمانی به طول ۲/۵ ثانیه

۳-۲-۲- ساختار پیشنهادی برای پنجره‌های زمانی ۵ ثانیه

شبکه پیشنهادی برای این بخش شامل ۵ لایه کانولوشن است و در مجموع حدود ۱۷۹ هزار پارامتر قابل آموزش دارد. ساختار این شبکه با جزئیات در شکل ۳-۴ قابل مشاهده است:


^۱ Python Programming Language



شکل ۳-۴: ساختار شبکه پیشنهادی برای پنجره زمانی به طول ۵ ثانیه

۳-۲-۳- ساختار پیشنهادی برای پنجره‌های زمانی ۷/۵ ثانیه


شبکه پیشنهادی برای این بخش شامل ۵ لایه کانولوشن است و در مجموع حدود ۲۴۷ هزار پارامتر قابل آموزش دارد. ساختار این شبکه با جزئیات در شکل ۳-۵ قابل مشاهده است:



شکل ۳-۵: ساختار شبکه پیشنهادی برای پنجره زمانی به طول ۷/۵ ثانیه

۳-۲-۴- ساختار پیشنهادی برای پنجره‌های زمانی ۱۰ ثانیه

شبکه پیشنهادی برای این بخش شامل ۵ لایه کانولوشن است و در مجموع حدود ۳۰۷ هزار پارامتر قابل آموزش دارد. ساختار این شبکه با جزئیات در شکل ۳-۶ قابل مشاهده است:



شکل ۳-۶: ساختار شبکه پیشنهادی برای پنجره زمانی به طول ۱۰ ثانیه

۳-۳- رویکرد دوم پروژه (پردازش تک کانال)

در مرحله دوم پروژه، هدف این بوده که این بار شبکه‌هایی را تنها به صورت تک کانال آموزش دهیم و نواحی مختلف مغز را از نظر مفید بودن برای تشخیص MCI بررسی کنیم. با انجام این کار می‌توان به جای ثبت سیگنال تمامی کانال‌ها، تنها از نواحی‌ای سیگنال دریافت و ثبت کرد که کمک بیشتری به تشخیص بیماری انجام می‌دهند و در نتیجه این کار، هزینه ثبت داده‌ها و پردازش‌های لازم نیز کمتر خواهد بود.

با توجه به نتایج پردازش تمام کانال‌ها (که در فصل ۵ مورد بحث قرار می‌گیرند)، در پردازش تک کانال بازه‌های زمانی به طول ۱۰ ثانیه انتخاب شدند. دلیل این موضوع صحت و حساسیت بالای این پنجره زمانی بوده است.

سپس به تعداد کانال‌های سیگنال EEG که ۱۹ عدد بود، ۱۹ شبکه عصبی پیچشی یک بعدی کاملاً مشابه ساختار شکل ۳-۶ که برای پنجره زمانی ۱۰ ثانیه پیشنهاد شده بود، با کانال‌های مجزا آموزش داده شدند. تنها تفاوت این شبکه‌ها با ساختار پیشنهادی شکل ۳-۶ این است که لایه ورودی دارای ابعاد $1 * 2560$ است. نتایج این بخش نیز در فصل ۵ مورد بررسی قرار می‌گیرند.

۳-۴- جمع‌بندی فصل

در این فصل ابتدا مشخصات داده‌های استفاده شده در پروژه شرح داده شدند و سپس نحوه تقسیم‌بندی آنها از لحاظ زمانی و همین‌طور برای آموزش و ارزیابی توضیح داده شد. در ادامه رویکرد پروژه در دو مرحله شرح داده شد. در مرحله اول مدل‌هایی بهینه بر پایه شبکه‌های عصبی پیچشی یک بعدی برای حالات مختلف تقسیم‌بندی زمانی داده‌ها و براساس تمام کانال‌ها ارائه شد و در مرحله دوم شبکه‌هایی تنها با کانال‌های مجزا مورد آموزش قرار گرفتند. در فصل بعد نتایج حاصل از بررسی این مدل‌ها ارائه و با هم مقایسه خواهند شد.

فصل ۴ - نتایج

۴-۱- نتایج پردازش تمام کانال‌ها

همانطور که در فصل قبل توضیح داده شد، در مرحله اول پروژه ابتدا با چهار حالت مختلف تقسیم‌بندی زمانی داده‌ها، شبکه‌هایی را با تمامی کانال‌های سیگنال EEG آموزش دادیم. جدول ۴-۱ نتایج بررسی این شبکه‌ها بعد از فرایند آموزش نشان می‌دهد. لازم به ذکر است تمامی معیارها بر اساس روش LOOCV محاسبه شده‌اند.

جدول ۴-۱: نتایج پردازش تمام کانال‌ها

اختصاصیت	حساسیت	دقت	صحت	تعداد پارامترها	بازه زمانی پنجره‌ها
٪ ۹۲/۴۹	٪ ۹۲/۴۶	٪ ۹۲/۰۱	٪ ۹۲/۴۸	۴۷۷۰۷۱	۲/۵ ثانیه
٪ ۸۹/۳۲	٪ ۹۴/۴۵	٪ ۸۹/۲۲	٪ ۹۱/۸	۱۷۸۷۳۵	۵ ثانیه
٪ ۹۲/۶۱	٪ ۹۸/۷۶	٪ ۹۲/۵۹	٪ ۹۵/۵۸	۲۴۷۰۵۵	۷/۵ ثانیه
٪ ۹۱/۶۳	٪ ۹۹/۱	٪ ۹۱/۷۲	٪ ۹۵/۲۴	۳۰۷۸۵۱	۱۰ ثانیه

از داده‌های جدول ۴-۱ مشاهده می‌شود که با افزایش طول پنجره زمانی دو معیار صحت و حساسیت افزایش می‌یابند. این موضوع به این دلیل قابل توجه است که در پنجره‌های زمانی با طول کم، تعداد ویژگی‌ها کم است و مدل قادر نیست از این تعداد ویژگی کم به صحت بسیار بالا برسد. در مقابل در پنجره‌های زمانی با طول بسیار زیاد، تعداد ویژگی‌ها بسیار زیاد و در مقابل تعداد نمونه‌ها کم است، بنابراین در این موارد نیز انتظار داریم صحت کاهش یابد. می‌توان نتیجه گرفت که طول پنجره در حدود بین ۷/۵ تا ۱۰ ثانیه در حالت بهینه خود قرار دارد. در ضمن از داده‌های جدول دیده می‌شود که بیشترین مقدار حساسیت مربوط به پنجره زمانی ۱۰ ثانیه است و معیار حساسیت در مسائل تشخیص در پزشکی اهمیت بالایی دارد، زیرا اگر این معیار مقدار کمی داشته باشد، بدین معنی است که بسیاری از نمونه‌های مثبت (بیمار) توسط مدل منفی (سالم) پیش‌بینی شده‌اند. در مسئله تشخیص MCI نیز، اگر شخص بیمار به درستی تشخیص داده نشود، ممکن است بیماری به نوعی زوال عقل پیشرفت کند و در این صورت امکان جلوگیری از پیشرفت بیماری وجود نخواهد داشت، بنابراین معیار حساسیت بسیار مهم خواهد بود.

۴-۲- نتایج پردازش تک کانال

در مرحله دوم پروژه هدف این بوده که این بار شبکه‌هایی را تنها به صورت تک کانال آموزش دهیم و نواحی مختلف مغز را از نظر مفید بودن برای تشخیص MCI بررسی کنیم.


با توجه به نتایج مرحله اول، در مرحله دوم بازه‌های زمانی به طول ۱۰ ثانیه انتخاب شدند. دلیل این موضوع صحت و حساسیت بالای این پنجره زمانی بود که در بخش پیشین بحث شد.

جدول ۴-۲ نتایج بررسی این شبکه‌ها بعد از فرایند آموزش نشان می‌دهد. لازم به ذکر است تمامی معیارها بر اساس روش LOOCV محاسبه شده‌اند.

جدول ۴-۲: نتایج پردازش تک کانال

شماره کانال	نام کانال	صحت	شماره کانال	نام کانال	صحت
۱	Fp1	٪ ۷۸/۰۹	۱۱	C4	٪ ۸۱/۴۷
۲	Fp2	٪ ۶۹/۴۱	۱۲	T4	٪ ۶۱/۷۷
۳	F7	٪ ۷۸/۱۸	۱۳	T5	٪ ۸۱/۸۷
۴	F3	٪ ۸۰/۰۷	۱۴	P3	٪ ۷۱/۶۵
۵	Fz	٪ ۸۱/۴۸	۱۵	Pz	٪ ۷۶/۸
۶	F4	٪ ۸۰/۸	۱۶	P4	٪ ۸۱/۰۲
۷	F8	٪ ۷۸/۹۹	۱۷	T6	٪ ۷۶/۷۹
۸	T3	٪ ۸۴/۲۴	۱۸	O1	٪ ۷۹/۵
۹	C3	٪ ۸۵/۹۷	۱۹	O2	٪ ۷۷/۹۵
۱۰	Cz	٪ ۸۱/۸	-	-	-

شکل ۴-۱ محل قرارگیری کانال‌های مختلف بر روی مغز و صحت مربوط به هر ناحیه را نشان می‌دهد:



شکل ۴-۱: محل قرارگیری کانال‌ها بر روی مغز و صحت مربوط به هریک

از جدول ۴-۲ و شکل ۴-۱ قابل ملاحظه است که بیشترین صحت‌ها مربوط به کانال‌های C3 و T3 بوده‌اند. کمترین صحت‌ها نیز مربوط به کانال‌های T4 و Fp2 هستند. به طور کلی و از روی شکل ۴-۲ می‌توان گفت که نیم‌کره چپ مغز در تشخیص بیماری اهمیت نسبتاً بیشتری داشته است.

۴-۳- مقایسه نتایج پروژه با یافته‌های پیشین

در پژوهش‌های قبلی که در این حوزه انجام شده است و بخشی از آنها در فصل ۱ مورد اشاره قرار گرفتند، در سه مورد صحت طبقه‌بندی حدود ۷۵، ۸۵ و ۹۲ درصد بود [۷، ۸، ۹]، اما در این پروژه بیشینه صحت حدود ۹۵ درصد است که عملکرد قابل توجهی دارد. ضمناً در مقایسه با روش‌های پیشین، این نکته قابل توجه است که در این پروژه هیچگونه مرحله استخراج ویژگی انجام نشده است و نتایج تنها با پردازش داده‌های خام بدست آمده‌اند. این موضوع نکته مثبتی برای این پروژه محسوب می‌شود. در بخش دوم پروژه، نتایج بدست آمده با نتایج یافته‌های پیشین مطابقت دارد. در مقاله‌ای که در سال ۲۰۲۱ منتشر شده است، از بررسی تک کانال‌ها مشاهده شده است که نیم‌کره سمت چپ مغز عملکرد بهتری در تشخیص اختلال شناختی خفیف دارد و کانال T3 بیشترین صحت را در حدود ۷۵ درصد داشته است [۲۴]. در این پروژه نیز مشاهده شد که نیم‌کره چپ عملکرد بهتری دارد و کانال T3 دومین

مقدار بیشینه صحت را به خود اختصاص داده است.

۴-۴- مزایا و معایب مدل پیشنهادی پروژه

در این بخش به ذکر مزایا و معایب رویکرد پیشنهادی پروژه می‌پردازیم.

مزایا:

- صحت و حساسیت بسیار بالا
- عدم نیاز به مرحله استخراج ویژگی
- کم‌هزینه بودن در مقایسه با رویکردهای تشخیص بالینی در پزشکی
- تشخیص بیماری در مدت زمان بسیار کوتاه‌تر در مقایسه با رویکردهای تشخیص بالینی در پزشکی

معایب:


- نیاز به پردازش‌های سنگین
- سرعت کم در مقایسه با روش‌های کلاسیک یادگیری ماشین

۴-۵- رابط کاربری گرافیکی (GUI)

در این بخش رابط کاربری گرافیکی‌ای که به منظور تشخیص مبتلایان به MCI طراحی شده است معرفی می‌شود. لازم به ذکر است این رابط کاربری با زبان برنامه نویسی پایتون و با کمک کتابخانه tkinter طراحی شده است.

این رابط به کاربر اجازه می‌دهد فایل سیگنال EEG را که به فرمت mat است انتخاب کند. سپس با استفاده از مدل‌های آموزش داده شده (شبکه‌های عصبی پیچشی) داده‌ها پردازش شده و پیش‌بینی مدل به عنوان نتیجه به کاربر اعلام می‌شود.

شکل‌های ۴-۲ و ۴-۳ تصاویری از رابط کاربری گرافیکی مربوطه را نشان می‌دهند:



شکل ۴-۳: نتیجه نمایش
داده شده توسط رابط
کاربری گرافیکی برای یک
داده نمونه



شکل ۴-۲: رابط کاربری گرافیکی طراحی شده

۴-۶- جمع‌بندی فصل

در این فصل نتایج حاصل از پروژه با دو رویکرد پردازش تمام کانال و پردازش تک کانال شرح داده و با نتایج پژوهش‌های پیشین مقایسه شد. در ادامه در ارتباط با مزایا و معایب رویکرد این پروژه بحث شد و در نهایت رابط کاربری گرافیکی طراحی شده برای ارتباط با کاربر معرفی گردید.

در فصل بعد به نتیجه‌گیری و ارائه پیشنهاد برای کارهای آینده در این حوزه پرداخته می‌شود.

فصل ۵- نتیجه‌گیری و پیشنهادها

در این پروژه هدف اصلی ارائه مدلی بر پایه روش‌های یادگیری عمیق بود که در کنار صحت بالا، بتواند بدون نیاز به هیچگونه مرحله استخراج ویژگی به تشخیص افراد مبتلا به MCI بپردازد. نتایج به دست آمده از هر دو رویکرد پروژه نشان می‌دهند که روش‌های یادگیری عمیق و به خصوص شبکه‌های عصبی پیچشی قدرت بالایی در حل این مسئله دارند و می‌توان مرحله استخراج ویژگی را نیز به آن‌ها سپرد. ضمناً در مقایسه با بسیاری از روش‌های پیشین، مدل پیشنهادی این پروژه صحت عملکرد بالاتری داشت. (بیشترین صحت حدود ۹۵ درصد و بیشترین حساسیت حدود ۹۹ درصد، حاصل از پردازش تمام کانال‌ها). از نتایج پردازش تمام کانال مشاهده شد که پنجره‌های زمانی به طول بین ۷/۵ تا ۱۰ ثانیه بیشترین اطلاعات برای تشخیص MCI را دربردارند. همچنین از نتایج پردازش تک کانال می‌توان به اهمیت بیشتر برخی نواحی مغز در تشخیص MCI پی برد. این نتایج نشان می‌دهند کانال‌های C3 و T3 و همین‌طور نیم‌کره چپ مغز اهمیت بیشتری در تشخیص بیماری دارند. با این یافته‌ها می‌توان در هنگام ثبت داده از کانال‌های کم اهمیت‌تر صرف نظر کرد و در نتیجه، نیاز به پردازش‌ها نیز کاهش خواهد یافت.

در آینده برای بهبود نتایج مسئله راهکارها و پیشنهادهایی وجود دارد، از جمله:

- **آموزش مدل‌ها با مجموعه داده بزرگتر:** به طور کلی مدل‌های مبتنی بر یادگیری عمیق با داده‌های بیشتر، بهتر آموزش می‌بینند. در این پروژه مجموعه داده تنها شامل ۶۰ نفر بود که نسبتاً تعداد کمی است. یکی از روش‌های بهبود عملکرد مدل پیشنهادی پروژه آموزش آن با مجموعه داده‌های بزرگتر و شامل افراد بیشتر است.
- **استفاده از ساختارهای دیگر یادگیری عمیق:** یکی دیگر از روش‌های بهبود نتایج استفاده از ساختارهای دیگر یادگیری عمیق مانند شبکه‌های عصبی بازگشتی در کنار شبکه‌های عصبی پیچشی است. شبکه‌های عصبی بازگشتی به طور کلی در پردازش داده‌های زمانی از جمله سیگنال‌های EEG صحت و عملکرد بالایی دارند و استفاده از آنها در کنار شبکه‌های عصبی پیچشی می‌تواند قدرت بیشتری به مدل‌ها ببخشد.
- **استفاده از روش انتقال یادگیری:** انتقال یادگیری روشی است که در آن بخشی از یک مدل را که قبلاً برای مسئله دیگری آموزش داده شده است، بدون تغییر نگه داشته و بخش باقی‌مانده را برای مسئله فعلی دوباره آموزش می‌دهیم. یکی از روش‌هایی که ممکن است به بهبود نتایج این پروژه کمک کند، استفاده از شبکه‌های عمیقی است که برای مسائل دیگر بر اساس سیگنال‌های EEG آموزش دیده‌اند، به گونه‌ای که بخشی از شبکه برای مسئله فعلی دوباره آموزش ببیند.

مراجع

- [1] Alzheimer's Association, "2015 Alzheimer's disease facts and figures", Alzheimer's Dement., vol. 11, p. 332, 2015.
- [2] L.E. Hebert, J. Weuve, P.A. Scherr, D.A. Evans, "Alzheimer disease in the United States (2010–2050) estimated using the 2010 census", Neurology., vol. 80, pp. 1778–1783, 2013.
- [3] J. Dauwels, F. Vialatte, A. Cichocki, "Diagnosis of Alzheimer's disease from EEG signals: where are we standing?" Curr. Alzheimer Res., vol. 7, pp.487–505, 2010.
- [4] Mayo Clinic Staff, "Mild cognitive impairment (MCI) Diagnosis & treatment", Sep, 2020. [Online]. Available: <https://www.mayoclinic.org/diseases-conditions/mild-cognitive-impairment/diagnosis-treatment/drc-20354583>
- [5] K. Basu, R. Sinha, A. Ong, T. Basu, "Artificial Intelligence: How is It Changing Medical Sciences and Its Future?", Indian J Dermatol, pp. 365-370, Sep, 2020.
- [6] Y. Shen, "Machine Learning Based Epileptic Seizure Detection for ResponsiveNeurostimulator System Optimization" J. Phys.: Conf. Ser. 1453 012089, January 2020. [Online]. Available: https://www.researchgate.net/publication/339683168_Machine_Learning_Based_Epileptic_Seizure_Detection_for_Responsive_Neurostimulator_System_Optimization
- [7] Morabito F C, et al., "Deep convolutional neural networks for classification of mild cognitive impaired and Alzheimer's disease patients from scalp EEG recording", IEEE 2nd Int. Forum on Research and Technologies for Society and Industry Leveraging a Better Tomorrow (RTSI), 2016
- [8] Kim D, Kim K, "Detection of Early Stage Alzheimer's Disease Using EEG Relative Power with Deep Neural Network", IEEE Engineering in Medicine and Biology Society Annual Int. Conf., 2018
- [9] Ieracitano C, Mammone N, Bramanti A, Hussain A and Morabito F C, "A convolutional neural network approach for classification of dementia stages based on 2D-spectral representation of EEG recordings Neurocomputing.", pp. 96–107, 2019
- [10] C. J. Huggins, et al., "Deep learning of resting-state electroencephalogram

signals for three-class classification of Alzheimer's disease, mild cognitive impairment and healthy ageing”, Journal of Neural Engineering, vol. 18, No. 4, June, 2021.

[11] Mayo Clinic Staff, “Mild cognitive impairment (MCI) Symptoms & Causes”, Sep, 2020. [Online]. Available: <https://www.mayoclinic.org/diseases-conditions/mild-cognitive-impairment/symptoms-causes/syc-20354578>

[12] Y. Ma, K. Liu, Z. Guan, X. Xu, X. Qian and H. Bao, “Background Augmentation Generative Adversarial Networks (BAGANs): Effective Data Generation Based on GAN-Augmented 3D Synthesizing”, Dec, 2018. [Online]. Available:

https://www.researchgate.net/publication/329533120_Background_Augmentation_Generative_Adversarial_Networks_BAGANs_Effective_Data_Generation_Based_on_GAN-Augmented_3D_Synthesizing

[13] GeeksforGeeks, “ML| Underfitting and Overfitting”, 2022. [Online]. Available: <https://www.geeksforgeeks.org/underfitting-and-overfitting-in-machine-learning/>

[14] B. Ayisha, “Confusion Matrix”. [Online]. Available: https://in2techs.com/confusion-matrix/?doing_wp_cron=1662665384.5744929313659667968750

[15] T. Huynh, “Deep Learning vs Machine Learning: What's the Difference?”, 2022. [Online]. Available: <https://dev.to/tmchuynh/deep-learning-vs-machine-learning-whats-the-difference-2opf>

[16] Sh. Saxena, “Understanding Machine Learning & Deep Learning”, 2020. [Online]. Available: <https://dltlabs.medium.com/understanding-machine-learning-deep-learning-f5aa95264d61>

[17] Y. LeCun, L. Bottou, Y. Bengio, P. Haffner, “Gradient-Based Learning Applied to Document Recognition”, 1989

[18] IndoML.com, “Convolutional Neural Networks (CNN) Introduction”. [Online]. Available: <https://indoml.com/2018/03/07/student-notes-convolutional-neural-networks-cnn-introduction/>

[19] machine-learning.paperspace.com, “Activation Function”. [Online]. Available: <https://machine-learning.paperspace.com/wiki/activation-function>

[20] S. Saha, “A Comprehensive Guide to Convolutional Neural Networks — the ELI5 way”, 2018. [Online]. Available: <https://towardsdatascience.com/a->

[comprehensive-guide-to-convolutional-neural-networks-the-eli5-way-3bd2b1164a53](#)

[21] A. B. Khalifa, H. Frigui, “Multiple Instance Fuzzy Inference Neural Networks”, 2016. [Online]. Available: https://www.researchgate.net/publication/309206911_Multiple_Instance_Fuzzy_Inference_Neural_Networks

[22] towardsai.net, “How, When, and Why Should You Normalize / Standardize / Rescale Your Data?”, 2019. [Online]. Available: <https://towardsai.net/p/data-science/how-when-and-why-should-you-normalize-standardize-rescale-your-data-3f083def38ff>

[23] J. Jordan, “Setting the learning rate of your neural network”, 2018. [Online]. Available: <https://www.jeremyjordan.me/nn-learning-rate/>

[24] M. Kashefpoor, H. Rabbani, M. Barekatain, “Supervised dictionary learning of EEG signals for mild cognitive impairment diagnosis”, Biomedical Signal Processing & Control, vol. 53, 101559, August, 2019.

[25] TMSi, “What is the 10-20 System for EEG?”, 2022. [Online]. Available: <https://info.tmsi.com/blog/the-10-20-system-for-eeg>

[26] G. Cha, et al., "Development of a Prediction Model for DemolitionWaste Generation Using a Random Forest AlgorithmBased on Small DataSet", Int. J. Environ. Res. Public Health, vol. 17, 2020. [Online]. Available: https://www.researchgate.net/publication/344613547_Development_of_a_Prediction_Model_for_Demolition_Waste_Generation_Using_a_Random_Forest_Algorithm_Based_on_Small_DataSets

پیوست ۱ - واژه‌نامه انگلیسی به فارسی

واژه فارسی	واژه انگلیسی
صحت	Accuracy
تابع فعال‌سازی	Activation Function
روش بهینه‌سازی آدا‌بوست	AdaBoost Optimization Method
روش بهینه‌سازی آدام	Adam Optimization Method
بیماری آلزایمر	Alzheimer's Disease
آمیلوئید بتا	Amyloid beta
هوش مصنوعی	Artificial Intelligence
شبکه‌های عصبی مصنوعی	Artificial Neural Networks
انتشار رو به عقب	Backward Propagation
واسط مغز-کامپیوتر	Brain-Computer Interface
ویتامین ب ۱۲	B12 Vitamin
طبقه‌بندی	Classification
ماتریس درهم‌ریختگی	Confusion Matrix
شبکه عصبی پیچشی	Convolutional Neural Network
تابع هزینه	Cost Function
آنترپی متقابل	Cross Entropy
سی تی اسکن	CT Scan
مجموعه داده	Dataset

واژه فارسی	واژه انگلیسی
استانداردسازی داده	Data Standardization
یادگیری عمیق	Deep Learning
شبکه‌های عصبی عمیق	Deep Neural Networks
زوال عقل	Dementia
الکتروانسفالوگرافی	Electroencephalography
استخراج ویژگی	Feature Extraction
فیلتر	Filter
انتشار رو به جلو	Forward Propagation
تبدیل فوریه	Fourier Transform
لایه تمام متصل	Fully Connected Layer
نرمال‌سازی گاوسی	Gaussian Normalization
عمومیت	Generality
گرادیان کاهشی	Gradient Descent
رابط کاربری گرافیکی	Graphical User Interface
میانگین همساز	Harmonic Mean
هیپوکامپ	Hippocampus
بخش‌بندی تصویر	Image Segmentation
کرنل	Kernel
نرخ یادگیری	Learning Rate
اجسام لوی	Lewy Bodies

واژه فارسی	واژه انگلیسی
یادگیری ماشین	Machine Learning
تصویربرداری تشدید مغناطیسی	Magnetic Resonance Imaging (MRI)
اختلال شناختی خفیف	Mild Cognitive Impairment (MCI)
پردازش زبان طبیعی	Natural Language Processing
نورون	Neuron
بیش‌برازش	Overfitting
حاشیه‌گذاری	Padding
بیماری پارکینسون	Parkinson's Disease
پریودوگرام	Periodogram
دقت	Precision
زبان برنامه‌نویسی پایتون	Python Programming Language
پوشش	Recall
شبکه عصبی بازگشتی	Recurrent Neural Network
حساسیت	Sensitivity
اختصاصیت	Specificity
اسپکتروگرام	Spectrogram
گام	Stride
یادگیری نظارت‌شده	Supervised Learning
پروتئین‌های تاو	Tau Proteins
داده ارزیابی	Test Data
داده آموزش	Train Data

واژه فارسی	واژه انگلیسی
انتقال یادگیری	Transfer Learning
کم‌برازش	Underfitting
تبدیل موجک	Wavelet Transform
وزن	Weight

Abstract

Mild cognitive impairment (MCI) is a neurocognitive disorder that involves cognitive impairments and occurs in elderly ages. MCI may occur as a transitional stage between normal aging and dementia, especially Alzheimer's disease. Therefore, diagnosis of MCI holds great significance and can prevent impairment from progressing and turning into Alzheimer's disease.

In this study, we intend to diagnose people with MCI using Deep Learning methods and based on EEG signals. Deep Learning includes some ways of pattern recognition, which has shown great power in recent years. Compared with Classic Machine Learning, the advantage of Deep Learning is that it does not need feature extraction. Feature extraction requires knowledge in the field of application and the type of data, while using Deep Learning, this will be done automatically. Moreover, if Deep Learning models are trained with a big dataset, they will have a significant performance. In this project, we have used Convolutional Neural Networks to diagnose people with MCI.

The data have been processed with two different methods: In the first method, we have trained models with all of the EEG channels, and in the second stage, each channel has been processed separately. All models have been trained with a dataset including 60 people (29 with MCI, 31 Healthy). To evaluate models, we have used LOOCV method. The results have been noticeable, and as the highest accuracy of the diagnosis problem, we have seen 95% for all-channel analysis and 85.97% for single-channel analysis, belonging to C3 channel. With the results of the second method, we can see that some brain regions are more important in the diagnosis of MCI, compared with the other regions. Results show that the left hemisphere has a higher importance in diagnosis of MCI.

Finally, a Graphical User Interface (GPU) has been implemented to receive data and predict whether a person is healthy or patient.

Keywords: Mild Cognitive Impairment (MCI), Deep Learning, Electroencephalography (EEG), Convolutional Neural Networks (CNN)



K.N.Toosi University of Technology
Faculty of Electrical Engineering

Thesis Submitted in Partial Fulfillment of the
Requirements for the Degree of Bachelor of Science (B.Sc.)
in Electrical Engineering

EEG-based Diagnosis of Mild Cognitive Impairment (MCI) Using
Deep Learning

By:

Mohammad Matin Bani Saedi

Supervisor:

Dr. Amirhossein Nikoofard

Advisor:

Dr. Ali Khadem

Summer 2022
